

Adatbázisok 1.

Relációs adatbázis tervezés – 4. rész

Funkcionális függőségek

Felbontások

Normálformák

Relációs sémák tervezése

- Cél: az anomáliák és a redundancia megszüntetése.
 - *Módosítási anomália (update anomaly)*
 - *Törlési anomália (deletion anomaly)*
 - *Beszúrási anomália (insertion anomaly)*

Példa: rosszul tervezett séma

Főnökök(név, cím, kedveltTeák, gyártó, kedvencTea)

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	???	E. G.	Tetley	???
Spock	Enterprise	Brisk	???	Brisk

Redundáns adat, a ??? helyén a
név -> cím kedvencTea és kedveltTeák -> gyártó FF-ek
felhasználásával tudjuk, mi szerepel.

A rosszul tervezettség anomáliákat is eredményez

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	Voyager	E. G.	Tetley	E. G.
Spock	Enterprise	Brisk	Lipton	Brisk

- **Módosítási anomália:** ha Janeway-t *Judyra* módosítjuk, megteesszük-e ezt minden sornál?
- **Törlési anomália:** ha már senki sem szereti a Brisk teát, azt sem fogjuk tudni, hogy ki gyártotta.
- **Beszúrási anomália:** ha nem lehet ismeretlen a kedveltTeákra vonatkozó érték, akkor nem tudunk felvenni egy teákat nem kedvelő főnököt

Relációk felbontása (*decomposition*)

- R relációt, $\{A_1, A_2, \dots, A_n\}$ attribútumokkal helyettesítsük $S(B_1, B_2, \dots, B_m)$ és $T(C_1, C_2, \dots, C_k)$ relációkkal úgy, hogy
 1. $\{A_1, A_2, \dots, A_n\} = \{B_1, B_2, \dots, B_m\} \cup \{C_1, C_2, \dots, C_k\}$
 2. $S = \Pi_{B_1, B_2, \dots, B_m}(R)$
 3. $T = \Pi_{C_1, C_2, \dots, C_k}(R)$

Veszteségmentes felbontás (*lossless join*)

- Ha $r = \Pi_{R_1}(r) \bowtie \dots \bowtie \Pi_{R_k}(r)$ teljesül, akkor az előbbi összekapcsolásra azt mondjuk, hogy **veszteségmentes**. Itt r egy R sémájú relációt jelöl és R attribútumainak részhalmazai az $R_1, \dots, R_k$.
- $\Pi_{R_i}(r)$ jelentése: r sorai az R_i attribútumaira projektálva.
- **Megjegyzés:** könnyen látható, hogy $r \subseteq \Pi_{R_1}(r) \bowtie \dots \bowtie \Pi_{R_k}(r)$ mindig teljesül. (Miért?)

R

A	B	C
a	b	c
d	e	f
c	b	c

R_1

A	B
a	b
d	e
c	b

R_2

B	C
b	c
e	f

Példa

- A szétvágás után keletkező relációk összekapcsolása nem veszteségmentes:

R

A	B	C
a	b	c
c	b	e

R₁

A	B
a	b
c	b

R₂

B	C
b	c
b	e

Boyce-Codd normálforma (*normal form*)

- R reláció *BCNF* normálformában van, ha minden $X \rightarrow Y$ nemtriviális FF-re R -ben X superkulcs.
 - *Nemtriviális*: Y nem része X -nek.
 - *Szuperkulcs*: tartalmaz kulcsot (ő maga is lehet kulcs).

Példa

Főnökök(név, cím, kedveltTeák, gyártó, kedvencTea)

FF-ek: név->cím kedvencTea, kedveltTeák->gyártó

- Itt egy kulcs van: {név, kedveltTeák}.
- A baloldalak egyik FF esetén sem szuperkulcsok.
- Emiatt az *Főnökök* reláció nincs BCNF normálformában.

Még egy példa

Teák(név, gyártó, gyártóCím)

FF-ek: $\text{név} \rightarrow \text{gyártó}$, $\text{gyártó} \rightarrow \text{gyártóCím}$

- Az egyetlen kulcs {név}.
- $\text{név} \rightarrow \text{gyártó}$ nem sérti a BCNF feltételét, de a $\text{gyártó} \rightarrow \text{gyártóCím}$ függőség igen.


BCNF-re való felbontás

- Adott R reláció és F funkcionális függőségek.
- Van-e olyan $X \rightarrow Y$ FF, ami sérti a BCNF-t?
 - Ha van olyan következmény FF F -ben, ami sérti a BCNF-t, akkor egy F -beli FF is sérti.
- Kiszámítjuk X^+ -t:
 - Ha itt nem szerepel az összes attribútum, X nem superkulcs.

R dekomponálása $X \rightarrow Y$ felhasználásával

- R -t helyettesítsük az alábbiakkal:
 1. $R_1 = X^+$.
 2. $R_2 = R - (X^+ - X)$.
- *Projektáljuk* a meglévő F -beli FF-eket a két új relációsémára.

Dekomponálási kép



Példa: BCNF dekompozíció

Főnökök(név, cím, kedveltTeák, gyártó, kedvencTea)

$F = \text{név} \rightarrow \text{cím}, \text{név} \rightarrow \text{kedvencTea},$
 $\text{kedveltTeák} \rightarrow \text{gyártó}$

- Vegyük $\text{név} \rightarrow \text{cím}$ FF-t:
- $\{\text{név}\}^+ = \{\text{név}, \text{cím}, \text{kedvencTea}\}.$
- A dekomponált relációsémák:
 1. Főnökök1(név, cím, kedvencTea)
 2. Főnökök2(név, kedveltTeák, gyártó)

Példa -- folytatás

- Meg kell néznünk, hogy az Főnökök1 és Főnökök2 táblák BCNF-ben vannak-e.
- Az FF-ek projektálása könnyű.
- A Főnökök1(név, cím, kedvencTea), az FF-ek név->cím és név->kedvencTea.
 - Tehát az egyetlen kulcs: {név}, azaz az Főnökök1 BCNF-ben van.

Példa -- folytatás

- Az $Főnök2(\underline{név}, \underline{kedveltTeák}, gyártó)$ esetén az egyetlen FF
 $kedveltTeák \rightarrow gyártó$, az egyetlen kulcs: $\{név, kedveltTeák\}$.
 - Sérül a BCNF.
- $kedveltTeák^+ = \{kedveltTeák, gyártó\}$, az $Főnök2$ felbontása:
 1. $Főnök3(\underline{kedveltTeák}, gyártó)$
 2. $Főnök4(\underline{név}, \underline{kedveltTeák})$

Példa -- befejezés

- Az *Főnökök* dekompozíciója tehát:
 1. *Főnökök1*(név, cím, kedvencTea)
 2. *Főnökök3*(kedveltTeák, gyártó)
 3. *Főnökök4*(név, kedveltTeák)
- A *Főnökök1* a főnökökről, a *Főnökök3* a teákról, a *Főnökök4* a főnökökről és kedvelt teáikról tartalmaz információt.

Példa – anomáliák?

név	cím	kedveltTeák	gyártó	kedvencTea
Janeway	Voyager	Brisk	Lipton	E. G.
Janeway	Voyager	E. G.	Tetley	E. G.
Spock	Enterprise	Brisk	Lipton	Brisk

1. Főnök1(név, cím, kedvencTea)
2. Főnök3(kedveltTeák, gyártó)
3. Főnök4(név, kedveltTeák)

név	cím	kedvencTea
Janeway	Voyager	E. G.
Spock	Enterprise	Brisk

kedveltTeák	gyártó
Brisk	Lipton
E. G.	Tetley

név	kedveltTeák
Janeway	Brisk
Janeway	E. G.
Spock	Brisk

Miért működik a BCNF?

- (R, F) esetén ha $R_1, \dots, R_k$ egy veszteségmentes felbontás, S_1, S_2 pedig R_1 veszteségmentes felbontása, akkor $S_1, S_2, R_2, \dots, R_k$ is veszteségmentes felbontás.
- Könnyen ellenőrizhető, hogy a BCNF felbontásos dián az R_1, R_2 veszteségmentes. Ehhez:
Feladat: bizonyítsuk be, hogy ha az $R(A, B, C)$ reláció esetén $B \rightarrow C$ teljesül, akkor az $R_1(A, B), R_2(B, C)$ felbontás mindig veszteségmentes.
- Minden két attribútumú séma BCNF normálformában van.
- A fentiekkel igazolható:
- Az algoritmus tehát valóban veszteségmentes felbontást ad, ám sajnos **exponenciális** lépésszámú is lehet a függőségek vetítése miatt.

Chase-teszt veszteségmentességhez I.

- Példa: adott $R(A, B, C, D)$, $F = \{ A \rightarrow B, B \rightarrow C, CD \rightarrow A \}$ és az $R_1(A, D)$, $R_2(A, C)$, $R_3(B, C, D)$ felbontás. Kérdés veszteségmentes-e a felbontás?
- Vegyük $R_1 \mid X \mid R_2 \mid X \mid R_3$ egy $t = (a, b, c, d)$ sorát. Bizonyítani kell, hogy t R egy sora. A következő tablót (*tableau*) készítjük el:

A	B	C	D
a	b_1	c_1	d
a	b_2	c	d_2
a_3	b	c	d

Itt pl. az (a, b_1, c_1, d) sor azt jelzi, hogy R -nek van olyan sora, aminek R_1 -re való levetítése (a, d) , ám ennek a B és C attribútumokhoz tartozó értéke ismeretlen, így egyáltalán nem biztos, hogy a t sorról van szó.

Chase-teszt veszteségmentességhez II.

- Az F-beli függőségeket használva egyenlővé tesszük azokat a szimbólumokat, amelyeknek ugyanazoknak kell lennie, hogy valamelyik függőség ne sérüljön.
 - Ha a két egyenlővé teendő szimbólum közül az egyik index nélküli, akkor a másik is ezt az értéket kapja.
 - Két indexes szimbólum esetén a kisebbik indexű értéket kapja meg a másik.
 - A szimbólumok minden előfordulását helyettesíteni kell az új értékkel.
- Az algoritmus véget ér, ha valamelyik sor t-vel lesz egyenlő, vagy több szimbólumot már nem tudunk egyenlővé tenni.

Chase-teszt veszteségmentességhez III.

A	B	C	D
a	b ₁	c ₁	d
a	b ₂	c	d ₂
a ₃	b	c	d

$A \rightarrow B$



A	B	C	D
a	b ₁	c ₁	d
a	b ₁	c	d ₂
a ₃	b	c	d

$B \rightarrow C$



A	B	C	D
a	b ₁	c	d
a	b ₁	c	d ₂
a ₃	b	c	d

$CD \rightarrow A$



A	B	C	D
a	b ₁	c	d
a	b ₁	c	d ₂
a	b	c	d

Chase-teszt veszteségmentességhez IV.

- Ha t szerepel a tablóban, akkor valóban R -nek egy sora, és mivel t -t tetszőlegesen választottuk, ezért a felbontás veszteségmentes.
- Ha nem kapjuk meg t -t, akkor viszont a felbontás nem veszteségmentes.
- Példa: $R(A, B, C, D)$, $F = \{ B \rightarrow AD \}$, a felbontás: $R_1(A, B)$, $R_2(B, C)$, $R_3(C, D)$.

A	B	C	D
a	b	c_1	d_1
a_2	b	c	d_2
a_3	b_3	c	d

$B \rightarrow AD$



A	B	C	D
a	b	c_1	d_1
a	b	c	d_1
a_3	b_3	c	d

Itt az eredmény jó ellenpélda, hiszen az összekapcsolásban szerepel $t = (a, b, c, d)$, míg az eredeti relációban nem.

Chase-teszt veszteségmentességhez V.

