

Szavak, nyelvek tulajdonságai, műveletei

A) Elméleti háttér

Definíció Ábécé: Egy véges, nemüres halmaz. Az ábécé elemeit **betűknek** nevezzük.

Egy V ábécé elemeiből képzett véges sorozatokat **V feletti szavaknak** vagy sztringeknek nevezzük. Egy $u = t_1 \cdots t_n$ szóban lévő betűk számát (n) a szó **hosszának** nevezzük. Jelölés: $|u| = n$. A 0 hosszú sorozat jelölése ε , ezt **üres szónak** nevezzük ($|\varepsilon| = 0$)

Példa: Legyen $V = \{a, b\}$, ekkor a és b a V ábécé két betűje. $abba$ és $aabba$ egy-egy V feletti szó. $|aabba| = 5$. $aabba$ és $baaba$ különböző szavak, bár mindkettő 5 hosszú valamint 3 a -t és 2 b -t tartalmaz. A betűk sorrendje számít!

Definíció V^* jelöli a V ábécé feletti szavak halmazát, beleértve az üres szót is.

$V^+ = V^* \setminus \{\varepsilon\}$ a **V ábécé feletti, nemüres szavak halmazát** jelöli.

Példa: $V = \{a, b\}$, ekkor $V^* = \{\varepsilon, a, b, aa, ab, ba, bb, aaa, aab, \dots\}$.

V^* szavainak egy lehetséges felsorolása a következő, melyet **hosszlexikografikus (shortlex) rendezésnek** nevezünk.

- Feltesszük, hogy az ábécé rendezett. (A fenti példában, mondjuk a előbb van, mint b .)
- A rövidebb szó mindig megelőzi a hosszabbat.
- Az azonos hosszúságú szavak ábécésorrendben (lexikografikusan) követik egymást (balról jobbra az első eltérést alapján rakjuk sorba a két szót).

Definíció Legyen V egy ábécé továbbá legyenek $u = s_1 \cdots s_n$ és $v = t_1 \cdots t_k$ V feletti szavak (azaz legyen $s_1, \dots, s_n, t_1, \dots, t_k \in V$). Ekkor az $uv := s_1 \cdots s_n t_1 \cdots t_k$ szót az u és v szavak **konkatenáltjának** nevezzük. (Az u szó betűi után írjuk a v szó betűit.)

Példa: Legyen $V = \{a, b\}$, valamint $u = abb$ és $v = aaba$ egy-egy V feletti szó. Ekkor $uv = abbaaba$.

Észrevétel: Nyilván $|uv| = |u| + |v|$. Adott ábécé feletti szavak a konkatenáció műveletére nézve egységelemes félcsoporthat alkotnak, melynek ε az egységeleme.

Definíció Legyen i nemnegatív egész szám és legyen u egy V ábécé feletti szó ($u \in V^*$). Az u szó **i -edik hatványa** alatt az u szó i darab példányának konkatenáltját értjük és u^i -vel jelöljük. Formálisan $u^0 := \varepsilon$, $u^i := uu^{i-1}$ ($i \geq 1$).

Példa: Legyen $V = \{a, b\}$ és legyen $u = abb$. Ekkor $u^0 = \varepsilon$, $u^1 = abb$, $u^2 = abbabb$ és $u^3 = abbabbabb$.

Definíció Legyen u egy V ábécé feletti szó. Az u szó u^R -gyel jelölt **tükörképén** vagy fordítottján azt a szót értjük, amelyet úgy kapunk, hogy u betűit fordított sorrendben írjuk le. Azaz ha $u = a_1 \cdots a_n$, $a_i \in V$, $1 \leq i \leq n$, akkor $u^R = a_n \cdots a_1$.

Példa:

Legyen $V = \{a, b\}$, valamint $u = abba$ és $v = baabba$ egy-egy V ábécé feletti szó. Ekkor $u^R = abba$ és $v^R = abbaab$.

Ha $u = u^R$, akkor u -t **palindrom** tulajdonságúnak, vagy **palindrómának** nevezzük.

Példa (folyt.): Tehát $abba$ egy palindróma.

Definíció Legyenek u és v V ábécé feletti szavak. u és v szót **azonosnak** mondjuk, ha mint szimbólumsorozatok elemről-elemre rendre megegyeznek. (Tehát $abb \neq bab$!!!)

Legyen V egy ábécé és legyenek u és v szavak V felett. Az u szó a v szó **részszoja**, ha $v = xuy$ teljesül, valamely $x, y \in V^*$ szavakra. Az u szó a v szó **valódi részszoja**, ha $u \neq v$ és $u \neq \varepsilon$.

Ha $x = \varepsilon$, akkor u -t a v szó **Prefixének** (kezdőszeletének), ha pedig $y = \varepsilon$, akkor u -t a v szó **Suffixének** (utótagjának, végszeletének) nevezzük.

Egy v szó **valódi Prefixei/Suffixei** az ε -tól és v -tól különböző Prefixei/Suffixei.

Megjegyzés: A Suffix nem a tükörkép szó Prefixe!!!

Definíció Legyen V egy ábécé, V^* egy L részhalmazát V feletti **nyelvnek** nevezzük.

Az üres nyelv (nyelv, amely egyetlen szót sem tartalmaz) jelölése $\emptyset$.

Megjegyzés: Mivel V^* egy végtelen halmaz, ezért vannak véges és végtelen nyelvek is.

Definíció Legyen V egy ábécé és legyenek L_1, L_2 nyelvek V felett (vagyis $L_1 \subseteq V^*$ és $L_2 \subseteq V^*$).

$L_1 \cup L_2 = \{u \mid u \in L_1 \text{ vagy } u \in L_2\}$ (az L_1 és az L_2 nyelv **uniója**)

$L_1 \cap L_2 = \{u \mid u \in L_1 \text{ és } u \in L_2\}$ (az L_1 és L_2 nyelv **metszete**)

$L_1 - L_2 = \{u \mid u \in L_1 \text{ és } u \notin L_2\}$ (az L_1 és az L_2 nyelv **különbsége**)

Az $L \subseteq V^*$ nyelv **komplementere** a V ábécére nézve az $\bar{L} = V^* - L$ nyelv.

Definíció Legyen V egy ábécé és $L_1, L_2 \subseteq V^*$. Az L_1 és az L_2 nyelvek **konkatenációján** az $L_1 L_2 = \{u_1 u_2 \mid u_1 \in L_1, u_2 \in L_2\}$ nyelvet értjük.

Példa: $V = \{a, b\}$, $L_1 = \{ab, bb\}$, $L_2 = \{\varepsilon, a, bba\}$,

$L_1 L_2 = \{ab\varepsilon, bb\varepsilon, aba, bba, abba, bbbba\} = \{ab, bb, aba, bba, abba, bbbba\}$.

Definíció Egy L nyelv **i -edik hatványát** $L^0 := \{\varepsilon\}$ és $L^i := LL^{i-1}$ ($i \geq 1$) definiálják.

Példa: $L = \{a, bb\}$.

$L^0 = \{\varepsilon\}$, $L^1 = \{a, bb\}$, $L^2 = \{aa, abb, bba, bbb\}$,

$L^3 = \{aaa, aabb, abba, abbb, bbaa, bbaab, bbbba, bbbbb\}$,

Definíció Az L nyelv **iteratív lezártja** (vagy röviden lezártja vagy Kleene-lezártja) alatt az $L^* = \bigcup_{i \geq 0} L^i$ nyelvet értjük. Az L nyelv **pozitív lezártja** alatt az $L^+ = \bigcup_{i \geq 1} L^i$ nyelvet értjük.

Észrevétel: Nyilvánvalóan, $L^+ = L^*$, ha $\varepsilon \in L$ és $L^+ = L^* - \{\varepsilon\}$ ha $\varepsilon \notin L$.

Példa: $L = \{a, bb\}$.

$L^0 = \{\varepsilon\}$, $L^1 = \{a, bb\}$, $L^2 = \{aa, abb, bba, bbb\}$,

$L^3 = \{aaa, aabb, abba, abbb, bbaa, bbaab, bbbba, bbbbb\}$,

$L^4 = \{aaaa, aaabb, aabba, \dots\}$, ...

Ezen szavak uniója együttesen alkotja L^* -t. L^+ ettől csak annyiban tér el, hogy nincs benne az ε szó.

Definíció Legyen V egy ábécé és legyen $L \subseteq V^*$. Ekkor $L^R = \{u^R \mid u \in L\}$ a **tükörképe** (megfordítása) az L nyelvnek.

Példa: $V = \{a, b\}$, $L = \{ba^{2n+1} \mid n \in \mathbb{N}\}$, ekkor $L^R = \{a^{2n+1}b \mid n \in \mathbb{N}\}$.

Definíció Egy $L \subseteq V^*$ nyelv **Prefixnyelvén** a $\text{Pre}(L) = \{u \mid u \in V^*, uv \in L \text{ valamely } v \in V^* \text{-ra}\}$ nyelvet értjük.

Egy $L \subseteq V^*$ nyelv **Suffixnyelvén** a $\text{Suf}(L) = \{u \mid u \in V^*, vu \in L \text{ valamely } v \in V^* \text{-ra}\}$ nyelvet értjük.

Példa: $L = \{cab, cbab\}$.

Ekkor $\text{Pre}(L) = \{\varepsilon, c, ca, cab, cb, cba, cbab\}$, $\text{Suf}(L) = \{\varepsilon, b, ab, cab, bab, cbab\}$.

Definíció Legyen V_1 és V_2 két ábécé. A $h : V_1^* \rightarrow V_2^*$ leképezést **homomorfizmusnak** nevezzük, ha teljesülnek a következő feltételek:

- h egyértelmű, azaz, minden $u \in V_1^*$ szóra pontosan egy $v \in V_2^*$ szó létezik, amelyre $h(u) = v$ teljesül.
- $h(uv) = h(u)h(v)$, minden $u, v \in V_1^* \text{-ra}$.

Észrevételek:

- A fenti tulajdonságokból következik, hogy $h(\varepsilon) = \varepsilon$. Világos, hiszen $h(\varepsilon) = h(\varepsilon\varepsilon) = h(\varepsilon)h(\varepsilon)$, így csak $h(\varepsilon) = \varepsilon$ lehet.
- Minden $u = a_1a_2 \cdots a_n$ szóra, ahol $a_i \in V_1$, $1 \leq i \leq n$, fennáll, hogy $h(u) = h(a_1)h(a_2) \cdots h(a_n)$. Ez azt jelenti, hogy elegendő a h leképezést V_1 elemein megadni, és ez automatikusan kiterjed $V_1^* \text{-ra}$.

Definíció Legyen $h : V_1^* \rightarrow V_2^*$ homomorfizmus. A h homomorfizmus **ε -mentes**, ha $h(u) \neq \varepsilon$ bármely $u \in V_1^+$ szóra.

Definíció Legyen $h : V_1^* \rightarrow V_2^*$ homomorfizmus. Az $L \subseteq V_1^*$ nyelv **h -homomorf** képén a $h(L) = \{h(u) \mid u \in L\} \subseteq V_2^*$ nyelvet értjük.

Példa: $V_1 = \{a, b\}$, $V_2 = \{b, c\}$, $L = \{a^nba^n \mid n \in \mathbb{N}\}$ $h(a) = cc, h(b) = cbb$.

Ekkor $h(L) = \{c^{2n+1}b^2c^{2n} \mid n \in \mathbb{N}\}$.

B) Mintapéldák:

1. Legyen $u = ababb$ és $v = cbb$

(a) $u^R = ?$

(b) $uv = ?$, $vu = ?$,

(c) Soroljuk fel u Prefixeit és Suffixeit!

(d) Adjuk meg u 0., 1., 2., 3. hatványát!

2. Általában: $\varepsilon^R = ?$, $(u^R)^R = ?$, $(uv)^R = ?$

3. Mutassuk meg, hogy a konkatenáció asszociatív, de nem kommutatív művelet!

4. $V = \{a, b\}$

$$L_1 = \{a^{2n+1}b \mid n \geq 0\}$$

$$L_2 = \{a^n b^n \mid n \geq 0\}$$

$$L_3 = \{a^{2n} \mid n \geq 0\}$$

(a) $L_1 \cap L_2 = ?$

(b) $L_2 \cap L_3 = ?$

(c) $L_1 \cap L_3 = ?$

(d) $L_1 \cup L_2 = ?$

(e) $L_1 L_2 = ?$

(f) $L_1^2 = ?$ (Mi lesz amúgy a 0. és az 1. hatvány?)

(g) $L_1^* = ?$

(h) $\text{Pre}(L_1) = ?$

(i) $\text{Suf}(L_1) = ?$

(j) $\bar{L}_3 = ?$ (a fenti V -re nézve). És a $V' = \{a\}$ ábécére nézve?

5. $L = \{(ab)^n b^{2n+1} \mid n \geq 0\}$, Tekintsük a $h(a) = xyy$, $h(b) = yy$ homomorfizmust. Határozzuk meg a $h(L)$ nyelvet!

6. Igaz-e véges nyelvekre az alábbi állítás? $|L_1 L_2| = |L_1| \cdot |L_2|$? És az hogy $|L^k| = |L|^k$?

C) Gyakorló feladatok:

1. Mutassuk meg, hogy a konkatenáció nyelvművelet asszociatív, de nem kommutatív
2. $(L^R)^R = L$,
3. ha $L_i \subseteq L'_i$ minden $i \in I$ -re, akkor $\bigcup_{i \in I} L_i \subseteq \bigcup_{i \in I} L'_i$,
4. ha $L_i \subseteq L'_i$ minden $1 \leq i \leq n$ -re akkor $L_1 L_2 \cdots L_n \subseteq L'_1 L'_2 \cdots L'_n$,
5. ha $L \subseteq L'$, akkor $L^* \subseteq (L')^*$,
6. $(L_1 L_2 \cdots L_n)^R = L_n^R \cdots L_2^R L_1^R$,
7. $(L^i)^R = (L^R)^i$, ahol $i \geq 0$
8. $(L^*)^R = (L^R)^*$,
9. $L^* L^* = L^*$,
10. $(L^*)^* = L^*$,
11. $(L_1 \cup L_2)^* = (L_1^* L_2^*)^*$,
12. $L_1(L_2 \cup L_3) = L_1 L_2 \cup L_1 L_3$,
13. az előző általánosítása: $L(\bigcup_{i \in I} L_i) = \bigcup_{i \in I} L L_i$,
14. $L_1(L_2 \cap L_3) \neq L_1 L_2 \cap L_1 L_3$.
15. Mutassuk meg, hogy: $L \subseteq \text{Pre}(L)$, $L \subseteq \text{Suf}(L)$.
16. Mutassuk meg, hogy: $\text{Pre}(L) = \text{Pre}(\text{Pre}(L))$, $\text{Suf}(L) = \text{Suf}(\text{Suf}(L))$.
17. Igaz-e minden nyelvre és minden homomorfizmusra, hogy $h(L)^R = h(L^R)$?