

Reguláris kifejezések

A) Elméleti háttér

Motiváció:

Vegyük észre, hogy minden véges nyelv reguláris. Tudjuk továbbá, hogy az $\mathcal{L}_3$ nyelvosztály (a reguláris nyelvek osztálya) zárt az unió, a konkatenáció és az iteratív lezárt műveletekre nézve.

Következésképpen, kiindulva véges számú véges nyelvből és az előzőekben felsorolt, ún. reguláris műveleteket véges sokszor alkalmazva reguláris nyelvet kapunk.

Kérdés az, hogy vajon ezzel az eljárással minden reguláris nyelvet elő tudunk-e állítani, azaz, ez a módszer elégséges-e az $\mathcal{L}_3$ nyelvosztály leírására?

Definíció Legyenek V és $V' = \{\emptyset, \varepsilon, \cdot, +, *, (,)\}$ diszjunkt ábécék. A V ábécé feletti **reguláris kifejezéseket** rekurzív módon a következőképpen definiáljuk:

1. $\emptyset$ reguláris kifejezés V felett,
2. ε reguláris kifejezés V felett,
3. a reguláris kifejezés V felett, ha $a \in V$,
4. Ha R reguláris kifejezés V felett, akkor R^* is reguláris kifejezés V felett,
5. Ha Q és R reguláris kifejezések V felett, akkor $(Q \cdot R)$ is,
6. Ha Q és R reguláris kifejezések V felett, akkor $(Q + R)$ is.

Megjegyzés: Sokszor a $\cdot$ műveleti jelet nem írjuk ki, $(Q \cdot R)$ helyett (QR) -t írunk.

Minden egyes R reguláris kifejezés egy-egy $L(R)$ -rel jelölt reguláris nyelvet határoz meg, amelyeket az alábbi rekurzióval definiálunk.

Definíció

1. $L(\emptyset) := \emptyset$,
2. $L(\varepsilon) := \{\varepsilon\}$,
3. $L(a) := \{a\}$ ($a \in V$),
4. $L(R^*) := L(R)^*$, ha R reguláris kifejezés,
5. $L(Q \cdot R) := L(Q)L(R)$, ha Q, R reguláris kifejezések,
6. $L(Q + R) := L(Q) \cup L(R)$, ha Q, R reguláris kifejezések.

Azaz a $*$, $\cdot$ és $+$ szimbólumok rendre a lezárt, a konkatenáció és az unió műveleteket jelölik.

Megjegyzés: $(Q + R)$ helyett használatosak még a $(Q | R)$ illetve a $(Q \cup R)$ jelölések is.

Megjegyzés: R -et és $L(R)$ -et sokszor azonosítjuk, például írunk olyat, hogy $ab^* = \{ab^n \mid n \in \mathbb{N}\}$.

Állítás: Legyenek P, Q és R reguláris kifejezések. Ekkor fennállnak a következő azonosságok:

1. $P + (Q + R) = (P + Q) + R$

2. $P \cdot (Q \cdot R) = (P \cdot Q) \cdot R$

3. $P + Q = Q + P$

4. $P \cdot (Q + R) = P \cdot Q + P \cdot R$

5. $(P + Q) \cdot R = P \cdot R + Q \cdot R$

6. $P^* = \varepsilon + P \cdot P^*$

7. $\varepsilon \cdot P = P \cdot \varepsilon = P$

8. $P^* = (\varepsilon + P)^*$

9. $P \cdot \emptyset = \emptyset \cdot P = \emptyset$

A zárójeleket akkor írjuk ki, ha szükségesek (műveletek prioritási sorrendje: $*$, konkatenáció, unió). $R^+ = RR^*$ és használhatjuk a természetes egész kitevőket, amivel az adott reguláris kifejezés kitevőszörös önmagával vett konkatenációját rövidítjük. (Például $(a^*b)^3 = a^*ba^*ba^*b$.)

Arden tétele: Adottak az R és Q reguláris kifejezések. A $X = R + X \cdot Q$ egyenletnek X -re vonatkozó megoldása $X = R \cdot Q^*$. Amennyiben $\varepsilon \notin L(Q)$, akkor az egyenletnek ez az egyetlen megoldása.

Példa: Az $X = ab^* + Xbc^*$ egyenlet egyértelmű megoldása $X = ab^*(bc^*)^*$.

Megjegyzés: $X = R + Q \cdot X$ esetén persze $X = Q^*R$ a megoldás.

B) Mintapéldák:

1. Gondoljuk végig, hogy melyik nyelvet jelölik az alábbi reguláris kifejezések!

(a) ab

(b) $a + b$

(c) $\varepsilon + ba$

(d) b^*

(e) ab^*

(f) $(a + b)a^*$

(g) $aa^* + ba^*$

(h) $a + ba^*$

(i) $(a + b)^*$

(j) $(aa)^*$

2. Oldjuk meg az alábbi egyenletrendszert!

$$X = ab^* + b + (aa^* + bb)X + babY \quad Y = bb + aa + bX + a(a + bb)^*Y$$

Megoldás:

Gauss-eliminációval. A 2.-ből kifejezzük Y -t X függvényében (Arden tétellel):

$$Y = (a(a + bb)^*)^*(bb + aa + bX), \text{ amiből átrendezéssel:}$$

$$Y = (a(a + bb)^*)^*(bb + aa) + (a(a + bb)^*)^*bX. \text{ Az első egyenletbe visszahelyettesítve:}$$

$$X = ab^* + b + (aa^* + bb)X + bab((a(a + bb)^*)^*(bb + aa) + (a(a + bb)^*)^*bX). \text{ Átrendezve:}$$

$$X = ab^* + b + bab((a(a + bb)^*)^*(bb + aa)) + ((aa^* + bb) + bab(a(a + bb)^*)^*bX). \text{ Amiből Ardennek:}$$

$$X = ((aa^* + bb + bab(a(a + bb)^*)^*b)^*(ab^* + b + bab((a(a + bb)^*)^*(bb + aa)))). \text{ Hasonlóan:}$$

$$Y = (a(a + bb)^* + b(aa^* + bb)^*bab)^*(bb + aa + b(aa^* + bb)^*(ab^* + b)).$$

C) Gyakorló feladatok:

1. Gondoljuk át a fenti állítás bizonyítását!

2. Írjuk le (szavakkal vagy formulákkal) az alábbi reguláris kifejezések által meghatározott nyelveket!

(a) $0(0 + 1)^*1$

(b) $((a + b)^*a(a + b)^*)^+$

(c) $(\varepsilon + 1)^*0^*001(111)^*$

3. Alkossunk reguláris kifejezéseket a következő nyelvekhez!

(a) $\{u \in \{0, 1\}^* \mid u \text{ legalább egy } 1\text{-est tartalmaz}\}$

(b) $\{u \in \{c, d\}^* \mid u \text{ második betűje } c, \text{ vagy } u \text{ pontosan két } d\text{-t tartalmaz}\}$

(c) $\{a^{2n+1}b \mid n \in \mathbb{N}\}^*$

(d) $\{u \in \{0, 1\}^* \mid u \text{ páros sok } 1\text{-est tartalmaz}\}$